



Entrenamiento de modelos y evaluación avanzada

Alex Martínez Martínez

Tabla de contenidos



01. Modelos Supervisados	/04
02. Evaluación de Modelos	/11
03. Validación Cruzada	/17
04. GridSearchCV	/18
05. Taller Benchmarking	/19

0. Enlaces



<https://github.com/almtav08/course-python-ml>





1. Modelos Supervisados

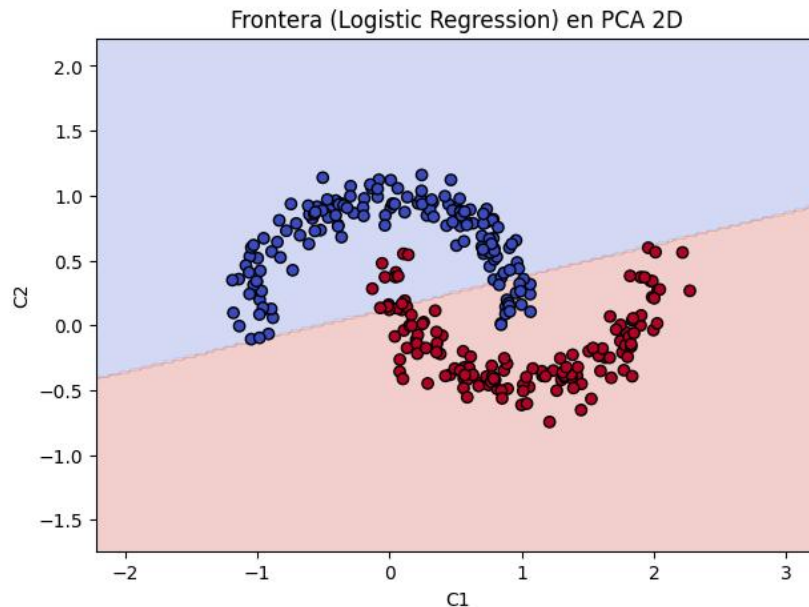
Descripción

- Un modelo supervisado es un tipo de modelo de aprendizaje automático que se entrena con un conjunto de datos etiquetados, es decir, cada ejemplo tiene sus características (X) y su respuesta correcta (y).
- Dentro del aprendizaje supervisado hay dos grandes tareas:
 - Clasificación → predecir etiquetas discretas (ej. spam / no spam).
 - Regresión → predecir valores numéricos continuos (ej. precio de una casa).
- Otros tipos de modelos:
 - No supervisados
 - Semisupervisados
 - Aprendizaje por refuerzo



1. Modelos Supervisados

Regresión Logística

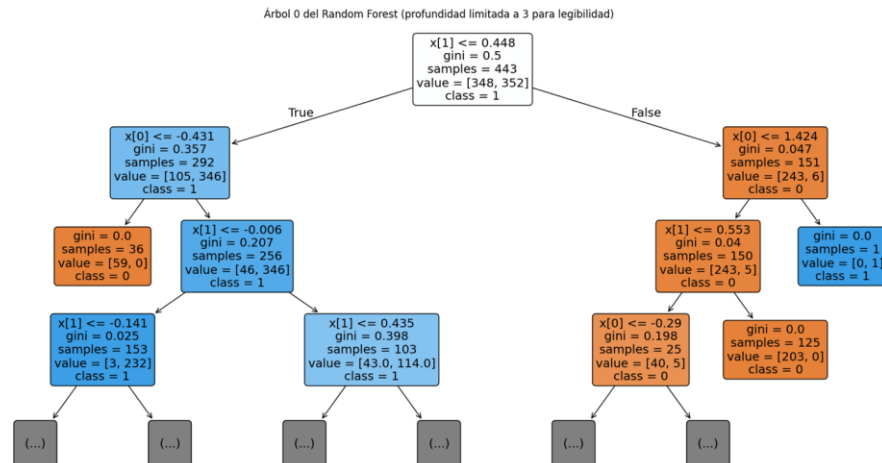


- La regresión logística es un modelo de aprendizaje supervisado usado principalmente para clasificación binaria (dos clases, como spam/no spam, aprobado/suspenso).
- Funcionamiento:
 - Combinación Lineal de las Características
 - Transforma ese resultado a un valor entre 0 y 1.
 - En base a ese valor decide si pertenece a una clase u otra con una función de activación.



1. Modelos Supervisados

Random Forest

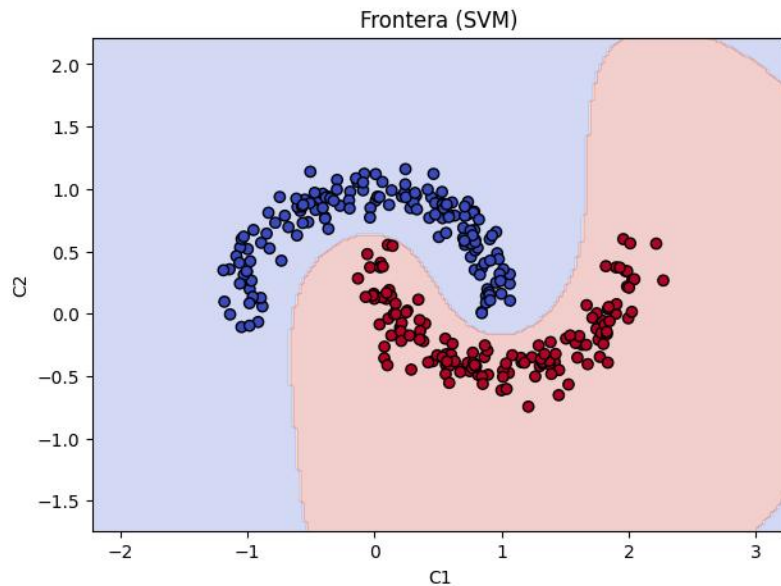


- Un árbol de decisión es un modelo de aprendizaje supervisado que se usa para clasificación y regresión. Su funcionamiento imita una especie de "diagrama de preguntas" que va dividiendo los datos hasta llegar a una decisión final.
- Funcionamiento:
 - El árbol formula preguntas basadas en una característica.
 - Cada camino da lugar a un nodo hoja que corresponde a la clase.



1. Modelos Supervisados

SVM



- El SVM busca encontrar un hiperplano (una línea en 2D, un plano en 3D, o una superficie en más dimensiones) que separe las clases de la mejor forma posible.
- Funcionamiento:
 - El SVM elige el hiperplano que deja la mayor distancia entre las dos clases.
 - Cuando las clases no se pueden separar en el espacio original, el SVM transforma los datos a un espacio de mayor dimensión.



1. Modelos Supervisados

Oversampling y Undersampling

- Es común encontrarnos con datos desbalanceados. Las clases en un conjunto de datos no están representadas de manera equitativa.
- Problema Principal: Este desbalance puede hacer que los modelos de aprendizaje automático ignoren la clase minoritaria.
- Soluciones:
 - Oversampling: Consiste en aumentar artificialmente los datos de la clase minoritaria.
 - Undersampling: Consiste en reducir el número de ejemplos de la clase mayoritaria para equilibrar el dataset.



1. Modelos Supervisados

Multiclase


- La clasificación multiclase es un tipo de problema de aprendizaje supervisado en el que los datos pueden pertenecer a más de dos clases posibles.
- Muchos algoritmos nativamente manejan multiclase (Random Forest)
- Otros que originalmente son binarios tienen que implementar estrategias:
 - One vs Rest: Se entrena un clasificador por cada clase contra todas las demás.
 - One vs One: Se entrena un clasificador para cada par de clases.
 - Softmax: Una **función de activación** que convierte las salidas en probabilidades para todas las clases a la vez.



1. Modelos Supervisados

Ajuste del modelo

- Tomemos como ejemplo la regresión logística multinomial. Cuenta con 2 tipos de parámetros (pesos W y sesgos b). La salida de este modelo son probabilidades.
- Aquí el modelo necesita ajustar sus parámetros para que las probabilidades predichas se acerquen lo más posible a las clases reales. **Función de pérdida.**
- El ajuste se hace mediante **descenso de gradiente**:
 - Inicialización de los parámetros.
 - Cálculo de la pérdida en los datos.
 - Derivadas (gradientes) \rightarrow indican en qué dirección cambiar los parámetros para reducir la pérdida.
 - Actualización iterativa de los parámetros.
 - Se repite hasta que el error se estabiliza.








1. Modelos Supervisados

Funciones de Activación

- Una función de activación es una transformación no lineal aplicada a la salida que permite al modelo aprender relaciones complejas más allá de lo lineal.





2. Evaluación de Modelos

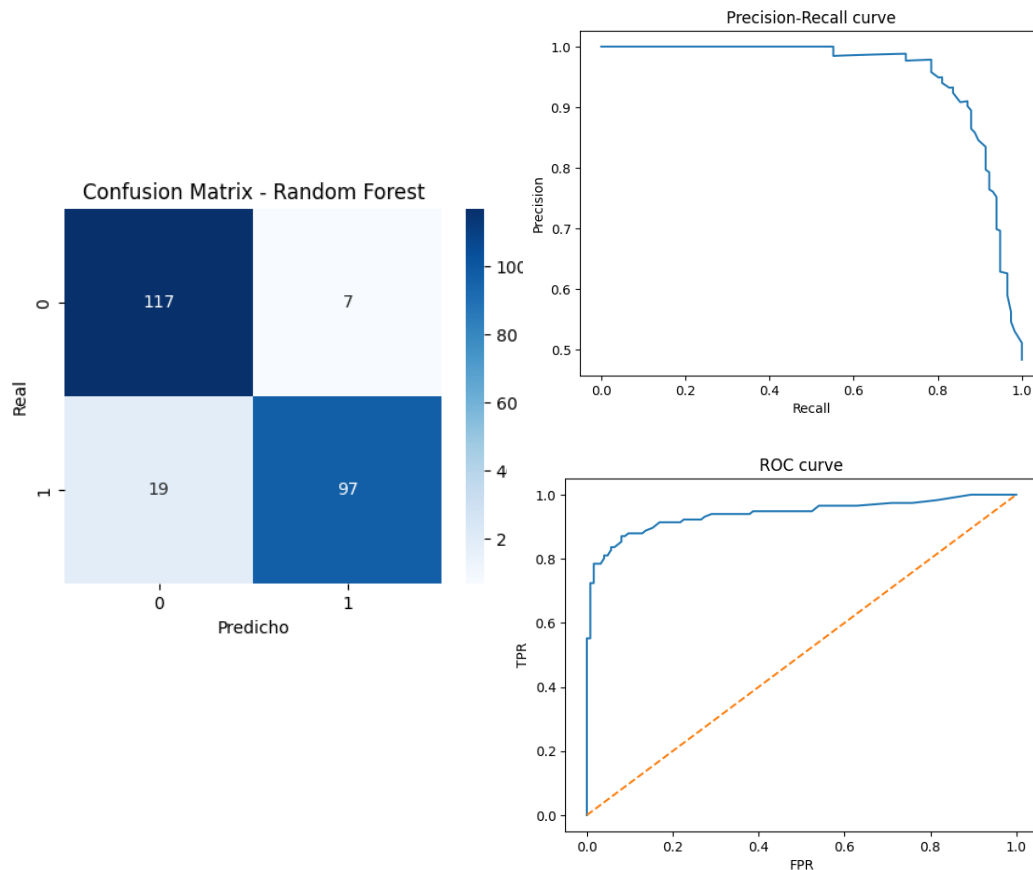
Objetivos

- La evaluación de modelos es el proceso de medir qué tan bien un modelo de cumple con la tarea para la que fue entrenado. Se utiliza para determinar su precisión, confiabilidad y capacidad de generalización a datos nuevos.
- No basta con que un modelo funcione con los datos que ya conoce, hay que comprobar que funcione también con datos que nunca ha visto.



2. Evaluación de Modelos

Métricas




- Accuracy: Proporción de predicciones correctas.
- Precision: Fracción de verdaderos positivos.
- Recall: Verdaderos positivos detectados.
- F1: Relación entre Precision y Recall.
- Curva ROC: Relación entre la tasa de verdaderos positivos y la tasa de falsos positivos.
- Matriz de confusión: Muestra los aciertos y errores de un modelo



2. Evaluación de Modelos

Overfitting y Underfitting



- Underfitting (subajuste): El modelo es demasiado simple y no logra capturar las relaciones de los datos. Tiene mal rendimiento tanto en el conjunto de entrenamiento como en el de prueba.
- Overfitting (sobreajuste): El modelo es demasiado complejo y se ajusta demasiado a los datos de entrenamiento, incluso al ruido. Tiene alto rendimiento en entrenamiento pero bajo rendimiento en prueba.



2. Evaluación de Modelos

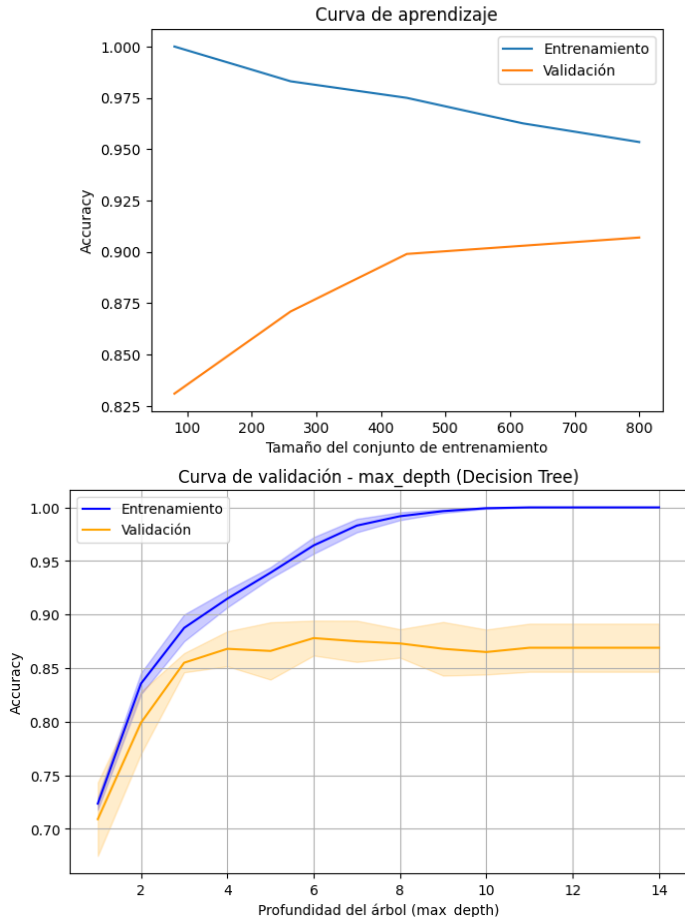
Regularización

- La regularización es una técnica que ayuda a un modelo a generalizar mejor a datos nuevos y evitar el overfitting.
- Tipos comunes de regularización:
 - L1 (Lasso): añade una penalización proporcional a la suma de los valores absolutos de los coeficientes. Promueve la sparsity (muchos coeficientes en cero).
 - L2 (Ridge): añade una penalización proporcional a la suma de los cuadrados de los coeficientes. Tiende a reducir los coeficientes pero no a hacerlos cero.



2. Evaluación de Modelos

Curvas de Validación y Aprendizaje




- Nos ayudan a diagnosticar el rendimiento de un modelo.
- Curva de aprendizaje: muestra cómo varía el rendimiento a medida que aumentamos el número de ejemplos de entrenamiento.
- Curva de validación: muestra cómo afecta un hiperparámetro al rendimiento en entrenamiento y validación.



2. Evaluación de Modelos

Interpretación de Modelos



- Busca entender cómo y por qué un modelo toma decisiones.
- Permite identificar qué variables son más importantes.
- Aumenta la confianza en el uso del modelo.
- Ayuda a detectar sesgos y mejorar el modelo.



3. Validación Cruzada

- La validación cruzada es una técnica para evaluar un modelo de manera más robusta y confiable, comprobando cómo se comporta con datos que no ha visto durante el entrenamiento.
- Funcionamiento:
 - Se divide el conjunto de datos en k partes (folds).
 - El modelo se entrena con $k-1$ partes y se prueba con la parte restante.
 - Se repite el proceso k veces, usando cada parte como conjunto de prueba una vez.
 - Se calculan métricas promedio para obtener una estimación más estable del rendimiento del modelo.
- Evita que la evaluación dependa de cómo se dividieron los datos y ayuda a detectar overfitting o underfitting.



4. GridSearchCV

- Técnica para encontrar los mejores hiperparámetros de un modelo probando sistemáticamente todas las combinaciones posibles en una “rejilla” (grid) y evaluándolas mediante validación cruzada.
- Automatiza la búsqueda del conjunto de parámetros que maximiza el rendimiento del modelo en datos no vistos, evitando ajustes manuales y sesgados.

5. Taller



¡Para el resto de la clase de hoy es hora de probar todo lo que hemos visto hasta ahora!

<https://github.com/almtav08/course-python-ml>



